

Ad Tracking Fraud Detection Challenge

Using LightGBM

Contents

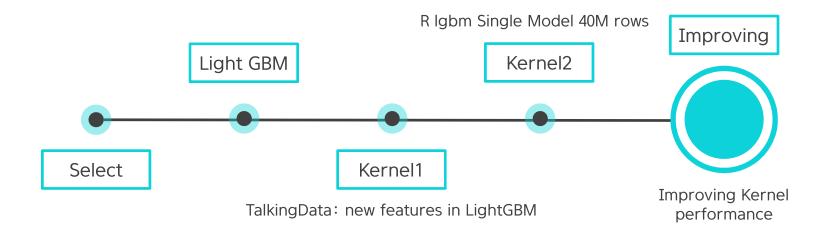
- 온라인 광고를 하는 회사의 경우 Click Fraud가 발생
- 'TalkingData'라는 회사는 Click Fraud를 방지하기 위해 IP and Device BlackList를 Build
- 이번 Competition의 목적은 광고를 클릭한 후 앱을 다운 받을지 여부를 예측

- 1 Select Kernel and Study
- 2 Kernel Implementation and Improving Performance



TimeLine



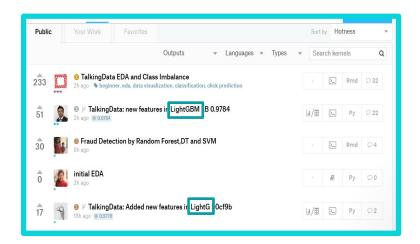


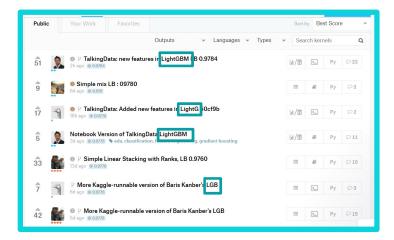
Select Kernel and Study



Select Kernel







Hotness

Best Score

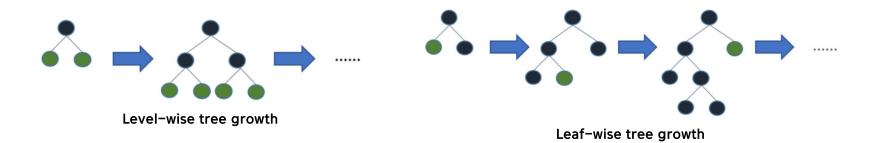
What is LightGBM





Light GBM 이란?

- 트리 기반 학습 알고리즘을 사용하는 gradient boosting framework
- Light GBM의 구현은 쉽지만 parameter tuning이 복잡하며 중요함



Control Parameters



Parameters	Meaning		
max_depth	• tree의 최대 깊이 • model이 overfitting 되었다고 느낄 때 max_depth를 낮춤		
min_data_in_leaf	• leaf가 가질 수 있는 최소 record 수 • default 20이며 최적값임, overfitting을 처리하는데 사용		
feature_fraction	• boosting이 임의의 forest일 때 사용 • 0.8이라면, parameter의 80%를 무작위로 선택한다는 것을 의미		
bagging_fraction	• 각 반복에 사용할 data의 비율을 지정함. • 일반적으로 training 속도를 높이고 overfitting을 피하는데 사용		
early_stopping_round	• 분석속도를 높일 수 있음 • 마지막 early_stopping_round에서 하나의 validation data 중에서 하나의 metric이 개선되지 않 으면 model이 training을 중지함. 이렇게 하면 과도한 iteration을 줄일 수 있음		
lambda	• 정규화를 지정, 일반적인 값의 범위는 0에서 1사이		
min_gain_to_split	• split을 수행하기 위한 최소 이득을 의미. tree에서 유용한 split수를 제어하는데 사용		
max_cat_group	• category수가 많으면 split point를 쉽게 찾을 수 없음. 그래서 LightGBM은 이들을 'max_cat_group'에 merge하고 그룹 경계에서 split point를 찾음		

Core Parameters



Parameters	Meaning
Task	• data에서 수행할 작업을 지정. train일수도 predict일수도 있음.
application	 가장 중요한 parameter. regression 문제인지 classification문제인지 관계 없이 모델 적용을 지정. default는 regression model regression, binary, multiclass
boosting	• 실행할 algorithm 유형을 정의 default = gdbt • gdbt : 전통적인 Gradient Boosting Decision Tree • rf : random forest • dart : Dropouts이 추가된 Multiple Additive Regression Trees • gross: Gradient-based One-Side Sampling
num_boost_round	• boosting iterations, 일반적으로 100+
learning_rate	 최종 output에 대한 각 tree의 impact를 결정함. GBM은 각 tree의 output을 사용하여 update되는 initial estimate으로 시작하여 작동함. learning_rate는 추정치의 변화량을 제어함. 일반적인 값: 0.1, 0.001, 0.003 ···
num_leaves	•전체 tree의 잎 수(number of leaves), default:31
device	• default : cpu, gpu도 가능함

Metric and IO Parameters



◆ Metric Parameters

• Metric : 중요한 Parameter는 Model building에서 loss를 지정하는 것임. Regression과 Classification에 대한 loss는 거의 없음.

Parameters	Meaning
mae	• mean absolute error
mse	• mean squared error
binary_logloss	loss for binary classification
multi_logloss	loss for multi classification

♦ IO Parameters

Parameters	Meaning
max_bin	• feature value가 bucket에 들어갈 수 있는 최대 bin 수를 의미.
categorical_feature	• categorical feature의 index를 의미. categoricla_features = 0,1,2이면 column1, column2, column3은 categorical variables임
ignore_column	• categorical_feature와 동일하지만 특정 column을 category로 간주하는 대신 완전히 무시함
save_binary	• data file의 memory size를 그대로 다루려면 True로 지정. • dataset을 binary file로 저장하므로 다음에 data file을 불러올 때 data reading 시간을 단축함

Kernel1. New Features

Python





Feature extraction

• 다른 Kernel 'Feature Engineering & Importance Testing'의 4가지 방법(Confidence Rates for is_attributed, Group-By-Aggregation, Time till next click, Clicks on app ad before & after) 중 Time till next click와 Group-By_Aggregation을 변형, 조합하여 사용함

(app, device, os, channel, hour)

- Feature extraction 방법 중 성능이 가장 좋게 나타난 Confidence Rates for is_attributed 소개
- 1. 일부 ip, app, device에서 is_attributed의 빈도가 더 높을 수 있으므로 그 정보를 "attributed rates"로 계산 P(is_attributed|category)

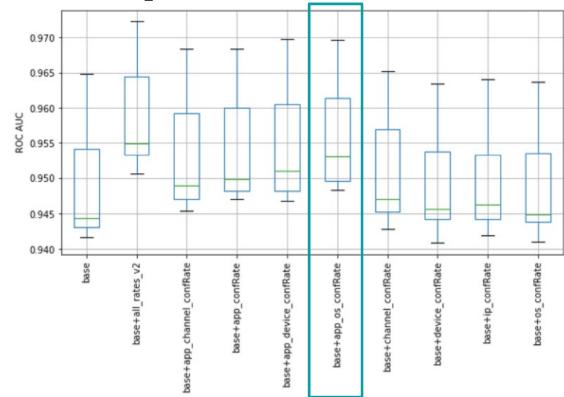
경우에 따라 2개 또는 여러 쌍으로 된 조합을 계산함

P(is attributed|category 1, category 2)

- 2. 주어진 category-combination의 클릭 수가 매우 적으면 위 방정식의 통계적 중요성을 신뢰할 수 없다는 것을 의미 log(views_category_i)/log(100,000)로 계산하여 가중치로 환산
 - (ex. 전체 data가 100,000개인 경우 category1에 1,000개의 관측치가 있는 경우 60%의 가중치를 얻고 100개의 관측치가 있는 경우 40%의 가중치를 얻음
- 3. xgBoost를 사용하여 천 만개의 샘플로 10-fold cross-validation score로 계산, 0.955에서 0.9624로 향상됨



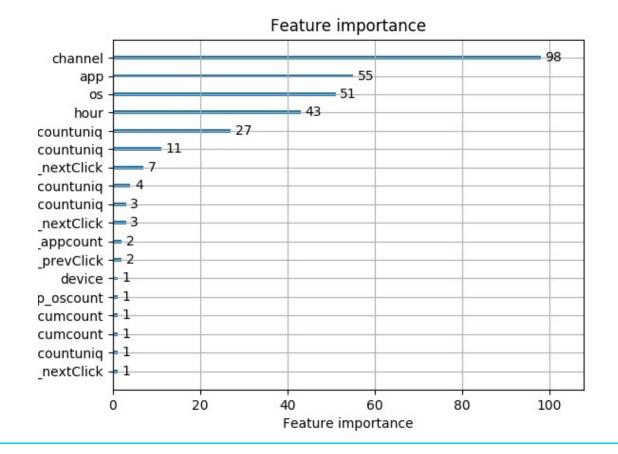
Confidence Rates for is_attributed





```
def lgb_modelfit_nocv(params, dtrain, dvalid, predictors, target='target', objective='binary', metrics='auc',
                    feval=None, early_stopping_rounds=50, num_boost_round=3000, verbose_eval=10,
                    categorical features=None):
   lgb_params = {
        'boosting_type' 'gbdt'.
       'objective': objective.
       'metric': metrics.
       'learning rate' 0.05.
       #'is_unbalance': 'true', #because training data is unbalance (replaced with scale_pos_weight)
       'num_leaves': 31, # we should let it be smaller than 2^(max_depth)
       'max_depth' -1, # -1 means no limit
       "min_child_samples": 20, # Minimum number of data need in a child(min_data_in_leaf)
        "max bin": 255. # Number of bucketed bin for feature values
        'subsample' 0.6. # Subsample ratio of the training instance.
        'subsample_freq': 0, # frequence of subsample, <=0 means no enable
        'colsample_bytree': 0.3, # Subsample ratio of columns when constructing each tree.
        imin_child_weight: 5, # Minimum sum of instance weight(hessian) needed in a child(leaf)
        'subsample for bin': 200000. # Number of samples for constructing bin
       in_split_gain : 0, # lambda_11, lambda_12 and min_gain_to_split to regularization
       'reg_alpha': 0, # L1 regularization term on weights
        'reg_lambda': 0, # L2 regularization term on weights
        'nthread': 8.
        'verbose' 0.
```







```
preparing validation datasets
C:\Python35\lib\site-packages\lightgbm\basic.py:1036: User\arming: Using categorical_feature in Dataset.
  warnings.warn('Using categorical_feature in Dataset.')
C:\Python35\lib\site-packages\lightgbm\basic.py:681: User\arning: categorical_feature in param dict is overrided.
  warnings.warn('categorical_feature in param dict is overrided.')
Training until validation scores don't improve for 30 rounds.
       valid's auc: 0.984957
[20]
       valid's auc: 0.987053
[30] valid's auc: 0.987685
[40] valid's auc: 0.990644
[50] valid's auc: 0.992448
[60] valid's auc: 0.990923
       valid's auc: 0.991524
       valid's auc: 0.991267
[80]
Early stopping, best iteration is:
[52]
       valid's auc: 0.992757
Model Report
bst1.best_iteration: 52
auc: 0.9927572547293558
[0.7615234851837158]: model training time
```

Kernel2. Single Model 40M





1. Sample data: 90만개

1-1 Train 모델 평가 결과 (AUC 이용)

• 10%는 test data, 90% train data

[LightGBM] [Info] Number of data: 832068, number of used features: 15

[1]: validation's auc:0.942413 [26]: validation's auc:0.968536 [51]: validation's auc:0.967458 [76]: validation's auc:0.967904

Validation AUC @ best iter: 0.9696



Kaggle 결과:

0.9471

04/28 약 2643/3540





1. Sample data: 90만개

1-2 변수의 중요도

Feature	Gain Cover I	Frequency	
:	: -	:	:
lapp	0.7810 0.4120	0.2414	
channel	0.1068 0.2573	0.3621	
n_app	0.0598 0.0895	0.0575	
los	0.0241 0.0774	0.1494	
nip_day_te	st_hh 0.0200 0.152	24 0.1264	
hour	0.0068 0.0098	0.0517	
device	0.0009 0.0002	0.0057	
UsrCount	0.0007 0.0014	0.0057	





2. Sample data: 180만개

2-1 Train 모델 평가 결과 (AUC 이용)

• 10%는 test data, 90% train data

[LightGBM] [Info] Number of data: 1664136, number of used features: 15

[1]: validation's auc: 0.954189

[26]: validation's auc: 0.969948

[51]: validation's auc: 0.972988

[76]: validation's auc:0.975103

[101]: validation's auc: 0.976007

[126]: validation's auc: 0.976754

[151]: validation's auc: 0.97707

[176]: validation's auc: 0.97727

[201]: validation's auc: 0.977393

[226]: validation's auc: 0.976856

[251]: validation's auc:0.976859

Validation AUC @ best iter: 0.9774

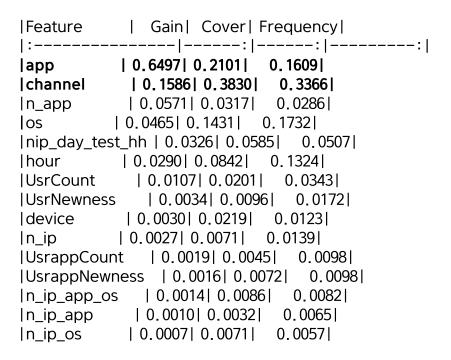






2. Sample data: 180만개

2-2 변수의 중요도







3. Sample data: 540만개

3-1 Train 모델 평가 결과(AUC 이용)

• 10%는 test data, 90% train data

[LightGBM] [Info] Number of data: 4992406, number of used features: 15

[1]: validation's auc: 0.951946

[26]: validation's auc: 0.963926

[51]: validation's auc: 0.96791

[76]: validation's auc: 0.969479

[101]: validation's auc: 0.970068

[126]: validation's auc: 0.970404

[151]: validation's auc: 0.970614

[176]: validation's auc: 0.970642

[201]: validation's auc: 0.970616

[226]: validation's auc: 0.970776

[220] · Validation's auc 0, 970/70

[251]: validation's auc:0.970656 Validation AUC @ best iter: 0.9708





3. Sample data: 540만개

3-2 변수의 중요도

```
| Gain| Cover| Frequency|
IFeature
                --|----:|----:|----:|
lapp
           | 0.7015| 0.2263| 0.1776|
Ichannel
            | 0.1140 | 0.3174 | 0.3084 |
In app
            | 0.0673 | 0.0456 |
                             0.0421
los
           0.0283 | 0.1222 |
                           0.17061
lhour
           | 0.0122| 0.0769|
                            0.10201
IUsrCount
            0.0084 | 0.0304 | 0.0366 |
Idevice
            0.0057 | 0.0260 |
                             0.0164
           0.0039 | 0.0219 |
In ip
                            0.02181
|UsrappCount | 0.0018 | 0.0198 | 0.0164 |
n_ip_app_os
             | 0.0015| 0.0222|
                               0.01711
UsrNewness
              | 0.0013 | 0.0036 | 0.0125 |
In ip app
             | 0.0008| 0.0033|
                             0.00701
|UsrappNewness | 0.0003 | 0.0021 | 0.0031 |
n_ip_os
            0.0002 | 0.0031 | 0.0023 |
```





4. Sample data: 900만개

Train 모델 평가 결과(AUC 이용)

• 10%는 test data, 90% train data

[176]: validation's auc:0.971962 [201]: validation's auc:0.972145 [226]: validation's auc:0.972241 [251]: validation's auc:0.972342 [276]: validation's auc:0.97259 [301]: validation's auc:0.972478 Validation AUC @ best iter: 0.9726





